

Aprendizado de Máquina e Reconhecimento de Padrões (UTFPR/CPGEI) - Lista de Exercícios 5

Tópicos: Extração de Características

1. Gere um conjunto de dados \mathbf{X}_1 bidimensional com 400 exemplos de duas classes distintas. Os primeiros 200 são da primeira classe, a qual é modelada por uma distribuição Gaussiana com média $[-8, 8]$, e os outros 200 com média $[8, 8]$. A matriz de covariância de ambas as classes é $\mathbf{S} = [0.3, 1.5; 1.5, 9.0]$.
 1. Aplique PCA em \mathbf{X}_1 e calcule o percentual da variância total explicada por cada componente.
 2. Repita o processo para um conjunto \mathbf{X}_2 . Altere as médias para $[-1, 0]$ e $[1, 0]$ e repita o processo.
 3. Compare os resultados.
2. Gere um conjunto de dados de 100 exemplos e dimensionalidade $l=2000$. Os vetores estão relacionados a uma distribuição Gaussiana com média nula (l -dimensional) e uma matriz de covariância diagonal \mathbf{S} , tendo todos os seus elementos diagonais iguais a 0.1, exceto $S(1,1)$ e $S(2,2)$, os quais são iguais a 10000. Aplique PCA e SVD e compare os resultados.
3. Gere um conjunto de dados tridimensional com 900 exemplos, os quais correspondem a duas classes – sendo os 100 primeiros com média nula e matriz de covariância $\mathbf{S}_1 = [0.5 \ 0 \ 0; 0 \ 0.5 \ 0; 0 \ 0 \ 0.01]$. Os demais estão organizados em 8 grupos de 100 exemplos. Cada grupo segue uma distribuição Gaussiana com a seguinte matriz de covariância: $\mathbf{S}_2 = [1 \ 0 \ 0; 0 \ 1 \ 0; 0 \ 0 \ 0.01]$. Sendo as médias:
 - $[a \ 0 \ 0]$;
 - $[a/2 \ a/2 \ 0]$;
 - $[0 \ a \ 0]$;
 - $[-a/2 \ a/2 \ 0]$;
 - $[-a \ 0 \ 0]$;
 - $[-a/2 \ -a/2 \ 0]$;
 - $[0 \ -a \ 0]$;
 - $[a/2 \ -a/2 \ 0]$.

Sendo $a=6$.

- a) Plote os dados em 3-D e visualize-os sob vários ângulos para perceber a organização dos dados no espaço.
 - b) Aplique o discriminante de Fischer nos dados. Projete os dados em um subespaço gerado pelos autovetores que correspondem aos autovalores não-negativos do produto das matrizes $\mathbf{S}_w^{-1}\mathbf{S}_b$ (ver dica do final do exemplo visto em aula). Comente os resultados.
4. Gere dois conjuntos de dados \mathbf{X} e $\mathbf{X}_{\text{teste}}$, sendo que cada um contém 200 exemplos tridimensionais. Em cada conjunto, os primeiros 100 exemplos são da classe 1, modelada através de uma distribuição uniforme em $[-0.5 \ 0.5]^3$, enquanto os demais 100 exemplos são da classe -1

e estão localizados em torno de uma esfera de raio 2 centrada na origem. Os exemplos da segunda classe são gerados como segue. Selecione aleatoriamente um par de números, $x(1)$ e $x(2)$, de uma distribuição uniforme no intervalo $[-2, 2]$ e cheque se $x^2(1) + x^2(2)$ é menor que r^2 . Se esse não for o caso, selecione um par diferente. Caso contrário, gere dois pontos da esfera como $(x(1), x(2), \sqrt{r^2 - x^2(1) - x^2(2)} + \varepsilon_1)$ e $(x(1), x(2), \sqrt{r^2 - x^2(1) - x^2(2)} + \varepsilon_2)$, sendo ε_1 e ε_2 números aleatórios de uma distribuição uniforme no intervalo $[-0.1, 0.1]$. Repita o processo 50 vezes para gerar 100 exemplos. Adicionalmente, gere os vetores de rótulos y e y_{teste} para os vetores X e X_{teste} . Em seguida, plote os dados.

1. Aplique a kernel PCA com um kernel exponencial e parâmetro 1, retendo apenas as duas primeiras componentes principais. Projete os dados no subespaço gerado pelas duas primeiras componentes principais, sendo Y o conjunto formado por essas projeções.
 2. Projete um classificador de mínimos quadrados baseado em Y .
 3. Avalie a performance do classificador no conjunto de teste mapeado para o espaço 2-D gerado pela kernel PCA.
 4. Repita o processo para o parâmetro do kernel igual a 0.6.
5. Gere uma espiral de Archimedes tridimensional como um pacote de 11 espirais de Archimedes bidimensionais idênticas, uma após a outra. Uma espiral bidimensional é descrita em coordenadas polares pela equação $r=a\theta$, onde a é um parâmetro definido pelo usuário. No caso, os pontos em uma espiral 3-D são gerados como segue. Para cada θ , utilize os valores de θ_{init} até θ_{fin} com passo θ_{step} e calcule:
- $R = a\theta$
 - $x = r\cos\theta$
 - $y = r\sin\theta$
- Os 11 pontos são na forma (x, y, z) , onde $z = -1, -0.8, -0.6, \dots, 0.8, 1$ são pontos da espiral. Utilize $a=0.1$, $\theta_{\text{init}} = 0.5$, $\theta_{\text{fin}} = 2.05*\pi$, $\theta_{\text{step}} = 0.2$. Plote a espiral 3-D de tal forma que todas as espirais 2-D sejam plotadas com o mesmo símbolo e todos os grupos de 11 pontos na forma (x, y, z) , onde x e y são fixados e z assume os valores $-1, -0.8, -0.6, \dots, 0.8, 1$, são plotados com a mesma cor.
- a) Aplique kernel PCA para uma dimensão $m=2$ para diferentes parâmetros do kernel Gaussiano e plote os resultados.
 - b) Repita o processo com PCA para os dois componentes principais.
 - c) Compare e comente os resultados.

Exemplo da espiral 2-D e 3-D:

